Classificação da resposta patológica completa ao tratamento do câncer de mama em DCE-MRI com redes neurais convolucionais

Bernardo PREENCHER[1], **Diego PREENCHER**[1],
Kauan PREENCHER[1], **Túlio PREENCHER**[1]

[1]Instituto de Ciências Exatas e Informática (ICEI)
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Curso de Ciência da Computação – Campus PREENCHER – Belo Horizonte – MG
Matrículas: PREENCHER, PREENCHER, PREENCHER, PREENCHER

PREENCHER@sga.pucminas.br

Abstract. *This work presents a system with a graphical interface that classifies pathological complete response (pCR) to breast cancer treatment from DCE-MRI, using the I-SPY1 subset of BreastDCEDL (172 patients). Three networks, a custom CNN and the pre-trained ResNet50 and VGG16, were trained with one phase and with the three temporal phases as channels, and evaluated with three ways of combining the slices of the volume. A tuning study with 126 training runs showed that the tested hyperparameters do not lift the networks above chance on the validation set. On the 35 test patients, the AUC ranged from 0.33 to 0.67 and the best classifier, ResNet50 with three phases, reached an accuracy of 0.71. Three phases gave a higher test AUC than one phase in all nine comparisons, but the difference is no larger than the measurement uncertainty, so the hypothesis could not be confirmed.*

Resumo. *Este trabalho apresenta um sistema com interface gráfica que classifica a resposta patológica completa (pCR) ao tratamento do câncer de mama a partir de DCE-MRI, usando o subconjunto I-SPY1 do BreastDCEDL (172 pacientes). Três redes, uma CNN própria e as pré-treinadas ResNet50 e VGG16, foram treinadas com uma fase e com as três fases temporais como canais, e avaliadas com três formas de combinar os cortes do volume. Um ajuste com 126 treinos mostrou que os hiperparâmetros testados não tiram as redes do nível do acaso na validação. Nos 35 pacientes de teste, a AUC ficou entre 0,33 e 0,67 e o melhor classificador, a ResNet50 com três fases, teve acurácia de 0,71. As três fases tiveram AUC de teste maior do que uma fase nas nove comparações, mas a diferença não supera a incerteza das medidas, e a hipótese não pôde ser confirmada.*

1. Introdução

A ressonância magnética dinâmica realçada por contraste (DCE-MRI) adquire imagens da mama antes e depois da injeção de um meio de contraste. A forma como o tumor realça ao longo do tempo ajuda a caracterizá-lo e a acompanhar a resposta ao tratamento. Em pacientes com câncer de mama, um desfecho de interesse é a resposta patológica completa (pCR): a ausência de células tumorais invasivas depois da quimioterapia neoadjuvante.

Prever a pCR a partir do exame feito antes do tratamento permitiria adaptar a terapia e planejar a cirurgia de forma individualizada.

Este trabalho desenvolve e avalia um sistema que classifica pacientes quanto à ocorrência de pCR usando somente as imagens de DCE-MRI. A hipótese investigada é a de que o uso conjunto das três fases temporais do exame (pré-contraste, pós-contraste precoce e pós-contraste tardio) melhora a classificação em relação ao uso de uma única fase. Para testá-la, três redes neurais foram treinadas em dois regimes de entrada, com uma fase e com três fases, e em três formas de combinar os cortes do volume.

O sistema é um programa único em Python, com interface gráfica, que lê e exibe os volumes com a segmentação do tumor, gera o aumento de dados, treina as redes e classifica uma imagem mostrando as regiões usadas na decisão com a técnica de Grad-CAM. A Seção 2 descreve os dados, a Seção 3 as técnicas, a Seção 4 as bibliotecas, a Seção 5 os resultados e a Seção 6 a discussão.

2. Dataset

O BreastDCEDL [Fridman et al. 2026] reúne exames de DCE-MRI de 2.070 pacientes em formato padronizado para aprendizado profundo. Foi usado o subconjunto I-SPY1 MinCrop, com 172 pacientes do estudo I-SPY1 [Hylton et al. 2012]. Cada paciente tem três volumes, um por fase temporal, e um volume com a segmentação do tumor, todos recortados em torno da lesão. Uma planilha informa a classe (pCR ausente ou presente), dados clínicos e a partição em treino, validação e teste, que foi mantida como publicada (Tabela 1).

Tabela 1. Pacientes e cortes com tumor em cada partição e classe.

	Pacientes			Cortes com tumor		
Partição	sem pCR	com pCR	total	sem pCR	com pCR	total
Treino	78	26	104	1.935	616	2.551
Validação	22	11	33	575	329	904
Teste	23	12	35	675	290	965
Total	123	49	172	3.185	1.235	4.420

A inspeção dos arquivos mostrou cinco características que orientaram a implementação. Primeiro, cada volume tem formato $(N, 256, 256)$: o primeiro eixo do arquivo é a direção z e cada plano xy tem 256×256 voxels. O número de cortes N varia de 10 a 72, com média 30. Segundo, as intensidades não têm escala fixa: o valor máximo do volume vai de 53 a 7.255 entre os exames, com mediana de 300, e um volume (pré-contraste do ISPY1_1187) tem uma região saturada em 65.535. Terceiro, todos os cortes centrais contêm tumor, mas a lesão ocupa em média só 2,0% da área desse corte (mediana de 1,3%). Quarto, cada paciente tem de 6 a 68 cortes com tumor, em média 25,7. Quinto, o índice do nome dos arquivos de fase nem sempre é 0, 1 e 2: em 31 pacientes é 0, 2 e 3 ou 0, 2 e 5. A ordem crescente do índice corresponde à ordem temporal e coincide com as colunas da planilha em 171 pacientes. No paciente ISPY1_1139 a planilha repete o mesmo índice para as duas fases pós-contraste, embora existam três arquivos distintos, por isso o programa usa a ordem dos arquivos.

3. Técnicas implementadas

3.1. Pré-processamento e formação da entrada

Cada volume é normalizado por z-score, com a média e o desvio padrão do próprio volume. Essa escolha remove a diferença de escala entre exames, que não tem relação com a doença, e entrega às redes pré-treinadas valores na faixa que elas esperam. As imagens não são redimensionadas: as três redes terminam em uma média global e aceitam a entrada de 256×256. No regime de **três fases**, as fases formam os três canais da imagem, na ordem temporal. No regime de **uma fase**, a entrada é o pós-contraste precoce, fase em que o realce do tumor é mais intenso.

3.2. Aumento de dados

Cada imagem gera dez variações: rotações de -20, -10, 0, 10 e 20 graus, aplicadas à imagem original e à espelhada horizontalmente. A rotação mantém o tamanho da imagem, usa interpolação bilinear e preenche os cantos com o valor do pixel mais próximo. As três fases recebem a mesma transformação, para continuarem alinhadas. No treino, uma das dez variações é sorteada para cada imagem a cada época, de modo que a rede vê todas ao longo do treino sem multiplicar o uso de memória por dez. Na validação do corte central, cada imagem entra com as dez variações, sempre as mesmas, o que torna a loss de validação mais estável. O teste usa a imagem original.

3.3. Tratamento do desbalanceamento

No treino há 78 pacientes sem pCR e 26 com pCR, uma proporção de 3 para 1. Sem tratamento, uma rede que responde sempre "sem pCR" atinge 75% de acurácia sem aprender nada. A estratégia adotada foi dar peso maior à classe pCR na função de perda: a entropia cruzada binária multiplica o erro dos exemplos positivos por $w = n_{\text{neg}}/n_{\text{pos}}$, calculado no treino ($w = 3{,}0$ no corte central e $w = 3{,}1$ com todos os cortes). Essa opção foi preferida ao aumento proporcional porque não repete os mesmos 26 pacientes, e à *focal loss* porque não acrescenta um hiperparâmetro a ajustar com tão poucos dados.

3.4. Combinação dos cortes do volume

As redes são bidimensionais e o exame é tridimensional. Foram investigadas três estratégias: (i) **corte central**, em que cada paciente é representado pelo corte $\lfloor N/2 \rfloor$; (ii) **todos os cortes com média**, em que a rede é treinada com todos os cortes que contêm tumor e a probabilidade do paciente é a média das probabilidades dos seus cortes; e (iii) **todos os cortes com máximo**, em que a probabilidade do paciente é a maior entre os seus cortes. As estratégias (ii) e (iii) usam o mesmo modelo treinado e multiplicam por 25 o número de imagens de treino, embora os cortes de um mesmo paciente sejam muito correlacionados.

3.5. Classificadores

A Figura 1 mostra as três redes. Todas produzem um único valor, que a função sigmoide converte na probabilidade de pCR.

CNN própria. Tem seis camadas com parâmetros: quatro convolucionais e duas totalmente conectadas. Os filtros são 3×3, como na VGG, e dobram a cada bloco (16, 32, 64 e 128) enquanto o *max pooling* reduz a imagem pela metade. A normalização em lote [Ioffe e Szegedy 2015] estabiliza o treino. Uma média global substitui a camada

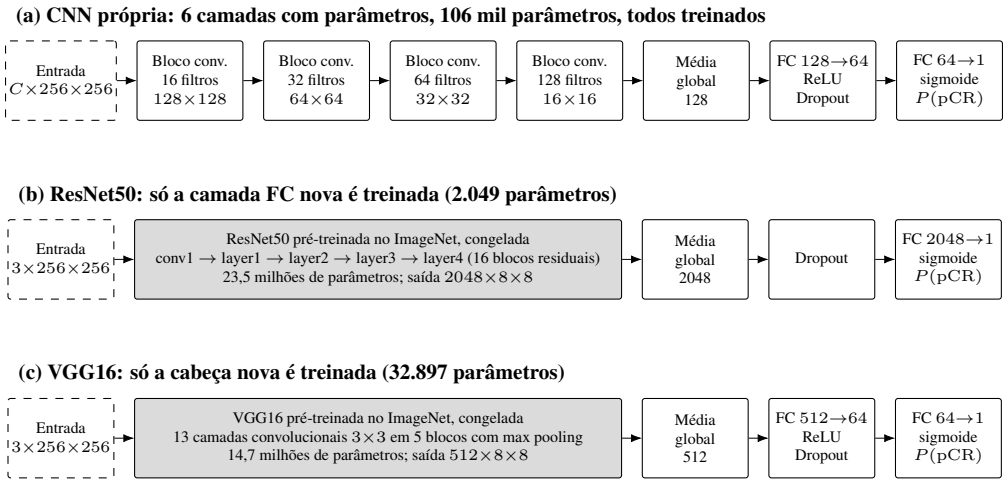


Figura 1. Topologia das três redes. Blocos brancos são treinados e blocos cinza ficam congelados. Cada bloco convolucional da CNN própria é Conv 3×3 + BatchNorm + ReLU + MaxPool 2×2. No regime de uma fase ($C = 1$), as redes pré-treinadas recebem o canal repetido três vezes.

totalmente conectada que ligaria os $128 \times 16 \times 16$ valores do último mapa: isso reduz a rede a 106 mil parâmetros, tamanho compatível com 104 pacientes de treino. O *dropout* [Srivastava et al. 2014] antes da última camada reduz a dependência de poucos neurônios.

ResNet50. Usa os pesos do ImageNet [He et al. 2016, Deng et al. 2009]. A base convolucional fica congelada e permanece em modo de avaliação durante o treino, para que a normalização em lote não altere as estatísticas aprendidas. A camada totalmente conectada original, de 1.000 classes, é trocada por *dropout* e uma camada de 2.048 entradas e uma saída, a única parte treinada. Na entrada, as três fases ocupam os três canais que a rede espera; no regime de uma fase o canal é repetido três vezes, o que preserva os filtros pré-treinados da primeira camada.

VGG16. É a terceira solução, escolhida por ter arquitetura sem conexões residuais e servir de contraponto à ResNet50 [Simonyan e Zisserman 2015]. As treze camadas convolucionais ficam congeladas. A cabeça original, com cerca de 120 milhões de parâmetros, é trocada por média global e duas camadas totalmente conectadas (512, 64 e 1 neurônios), com 33 mil parâmetros.

3.6. Treinamento e escolha do limiar

As redes são treinadas com o otimizador Adam [Kingma e Ba 2015] e a entropia cruzada binária ponderada. A cada época a loss é medida na validação; os pesos da época de menor loss de validação são salvos e o treino para depois de um número de épocas sem melhora (*early stopping*). O arquivo salvo contém todos os pesos da rede e é recarregado pela interface, sem novo treino.

A classe prevista é pCR quando a probabilidade atinge um limiar. Além do limiar fixo em 0,5, foi avaliado um limiar escolhido na validação, o que maximiza o índice de Youden [Youden 1950], igual à sensibilidade mais a especificidade menos um. Esse índice dá o mesmo peso às duas classes. Maximizar o F1 levaria a classificar quase todos como pCR, porque com 33% de positivos essa resposta já alcança F1 de 0,50. O limiar é

escolhido só com a validação e depois aplicado ao teste. Como medida independente de limiar, também é calculada a área sob a curva ROC (AUC), em que 0,5 corresponde ao acaso.

3.7. Grad-CAM e interface

O Grad-CAM [Selvaraju et al. 2017] pondera os mapas de ativação da última camada convolucional pela média do gradiente da saída em relação a cada mapa, soma os mapas e mantém a parte positiva. O resultado, ampliado para 256×256, indica as regiões que aumentam a saída de pCR. Para medir a relação com o tumor, duas grandezas são calculadas no conjunto de teste com a máscara de segmentação: a fração das imagens em que o ponto mais quente do mapa cai dentro do tumor e a fração do calor total do mapa que fica dentro do tumor. Esta última é comparada com a fração da imagem que o tumor ocupa, valor esperado para um mapa espalhado ao acaso.

A interface, feita com CustomTkinter, lista os arquivos de uma pasta, mostra o corte xy com a segmentação ao lado e permite percorrer a direção z com um controle deslizante. Outros comandos mostram as dez variações do aumento de dados, a contagem das classes, o treino de uma rede e a classificação do corte exibido, com a probabilidade, a classe prevista, a classe real e o mapa do Grad-CAM sobreposto à imagem com o contorno do tumor.

4. Bibliotecas e hiperparâmetros

A Tabela 2 lista as bibliotecas e as funções usadas. O código principal é próprio: as bibliotecas fornecem leitura de arquivos, operações elementares, as camadas de rede do PyTorch [Paszke et al. 2019] e os pesos pré-treinados. A Tabela 3 reúne os hiperparâmetros do treino final.

Tabela 2. Bibliotecas, principais funções e parâmetros usados.

Biblioteca	Funções	Parâmetros e finalidade
NiBabel	`load`, `get_fdata`	leitura dos volumes `.nii.gz`
NumPy e Pandas	vetores, `read_csv`	manipulação das imagens e da planilha
SciPy	`ndimage.rotate`	`reshape=False`, `mode="nearest"`, `order=1`
PyTorch	`Conv2d`, `BatchNorm2d`, `MaxPool2d`, `Linear`, `Dropout`, `BCEWithLogitsLoss`, `Adam`, `DataLoader`	filtros 3×3 com `padding=1`; *pooling* de 2; `pos_weight` igual à razão entre as classes; demais valores na Tabela 3
Torchvision	`resnet50`, `vgg16`	pesos `IMAGENET1K_V2` e `IMAGENET1K_V1`
Scikit-learn	`confusion_matrix`, `roc_auc_score`	matriz de confusão e AUC
Matplotlib	`imshow`, `plot`, `contour`	figuras e desenho na interface
CustomTkinter	janelas, botões e menus	interface gráfica

Tabela 3. Hiperparâmetros do treino final.

Hiperparâmetro	Valor	Justificativa
Otimizador	Adam	adapta o passo de cada peso e exige pouco ajuste
Taxa de aprendizado	10^{-3}	menor loss de validação entre 10^{-3} e 10^{-5} (Seção 5.1)
Decaimento de pesos	10^{-2}	regularização L2; menor loss de validação do ajuste
Dropout	0,5	valor usual; 0,7 não trouxe ganho
Tamanho do lote	16	7 lotes por época no corte central; 32 não trouxe ganho
Épocas e paciência	40 e 8 (central); 15 e 4 (todos)	com todos os cortes cada época tem 25 vezes mais imagens
Função de perda	entropia cruzada binária ponderada	trata o desbalanceamento de 3 para 1
Limiar de decisão	escolhido na validação	índice de Youden; comparado com o limiar fixo em 0,5
Entrada	256×256, z-score por volume	sem redimensionar; remove a escala de cada exame
Semente	42	reprodutibilidade; o ajuste usa também 43 e 44

5. Resultados

Os experimentos rodaram em um computador com processador Apple M4 Pro e 24 GB de memória, usando a GPU integrada pelo *backend* MPS do PyTorch.

5.1. Ajuste de hiperparâmetros

Na primeira rodada de experimentos, com valores usuais (T1 na Tabela 4), todas as redes ficaram perto do acaso e a loss de validação subia já nas primeiras épocas. Para verificar se a causa estava nos hiperparâmetros, sete configurações foram comparadas na estratégia do corte central, que treina em menos de um minuto por modelo. Cada configuração treinou as três redes nos dois regimes com três sementes, em 18 treinos por tentativa e 126 no total. A comparação usa só a validação: a loss, que é o critério do *early stopping*, e a AUC. O conjunto de teste não foi consultado nesta etapa.

Tabela 4. Tentativas de ajuste no corte central. A AUC de validação é a média $\pm$ desvio padrão de seis treinos (dois regimes e três sementes). A loss de validação e a melhor época são médias dos 18 treinos.

	Taxa de	Decaim.			AUC de validação			Loss de	Melhor
Tent.	aprend.	de pesos	*Dropout*	Lote	CNN	ResNet50	VGG16	valid.	época
T1	10^{-3}	10^{-4}	0,5	16	0,42 $\pm$ 0,18	0,47 $\pm$ 0,05	0,55 $\pm$ 0,02	1,142	6,1
T2	$3{\cdot}10^{-4}$	10^{-4}	0,5	16	0,44 $\pm$ 0,10	0,46 $\pm$ 0,08	0,51 $\pm$ 0,06	1,153	6,5
T3	10^{-4}	10^{-4}	0,5	16	0,40 $\pm$ 0,13	0,45 $\pm$ 0,09	0,54 $\pm$ 0,10	1,155	6,3
T4	10^{-5}	10^{-4}	0,5	16	0,43 $\pm$ 0,12	0,46 $\pm$ 0,10	0,55 $\pm$ 0,09	1,155	12,2
T5	10^{-3}	10^{-2}	0,5	16	0,59 $\pm$ 0,20	0,47 $\pm$ 0,05	0,54 $\pm$ 0,02	**1,136**	7,9
T6	10^{-3}	10^{-4}	0,7	16	0,50 $\pm$ 0,19	0,46 $\pm$ 0,08	0,56 $\pm$ 0,06	1,146	7,6
T7	10^{-3}	10^{-4}	0,5	32	0,51 $\pm$ 0,14	0,47 $\pm$ 0,05	0,54 $\pm$ 0,06	1,143	6,3

A primeira etapa variou a taxa de aprendizado (T1 a T4). Taxas menores não ajudaram: a loss de validação subiu de 1,142 para 1,155. Com 10^{-5}, a loss de treino das

três redes terminou entre 1,04 e 1,05, praticamente onde começou. Esse é o valor de uma rede que responde 0,5 para todas as imagens, o que caracteriza *underfitting* (Figura 2). Com 10^{-3}, a loss de treino cai desde o início e a melhor época de validação chega cedo, em média na sexta. Depois dela a loss de validação sobe enquanto a de treino continua caindo, sinal de *overfitting* que o *early stopping* interrompe.

A segunda etapa partiu de T1 e variou um fator por vez. O decaimento de pesos de 10^{-2} (T5) deu a menor loss de validação e a maior AUC média entre as sete tentativas (0,53). O ganho vem da CNN própria, única rede com todas as camadas treinadas, em que a AUC de validação passou de 0,42 para 0,59. Nas redes pré-treinadas, que só treinam a cabeça, o efeito foi nulo. *Dropout* de 0,7 (T6) e lote de 32 (T7) ficaram no nível de T1. A configuração T5 foi adotada no treino final.

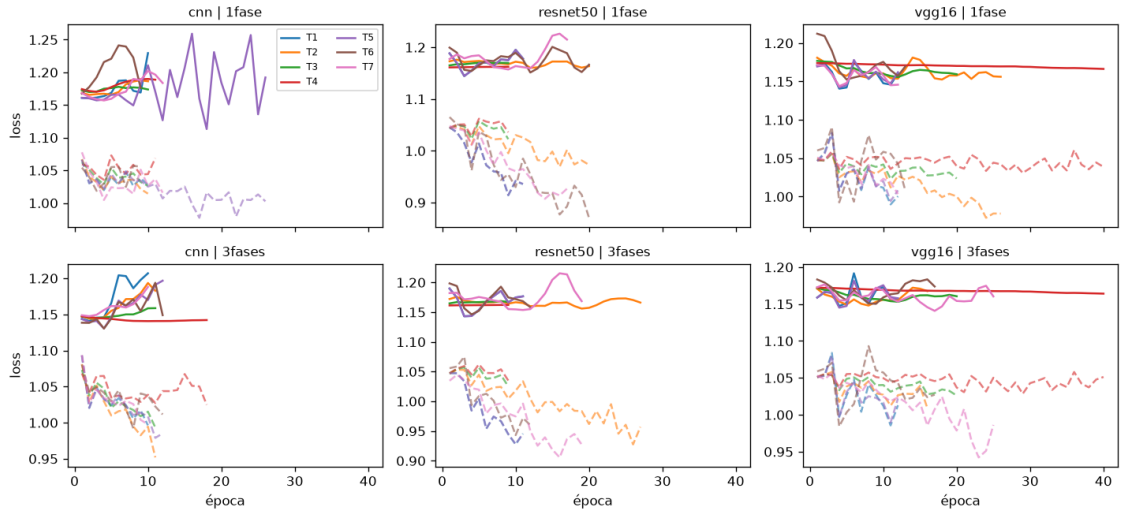


Figura 2. Convergência nas sete tentativas (semente 42): loss de validação em linha cheia e loss de treino em linha tracejada.

Duas ressalvas são necessárias. A loss de validação de uma rede que responde 0,5 para todos é 1,155, e todas as tentativas ficaram a menos de 0,02 desse valor. Além disso, o desvio padrão da AUC entre sementes, de até 0,20, é maior do que a diferença entre tentativas. O ajuste não revelou uma configuração que separe as classes: ele indica que o limite do desempenho não está nesses hiperparâmetros.

5.2. Treino final

Com a configuração T5, as três redes foram treinadas nos dois regimes, com o corte central e com todos os cortes, em 12 modelos. Como os modelos de todos os cortes são avaliados com média e com máximo, há 18 classificadores. A Tabela 5 traz o resultado no conjunto de teste, de 35 pacientes (12 com pCR), com o limiar escolhido na validação. O treino levou de 18 a 44 segundos por modelo no corte central e de 57 a 137 segundos com todos os cortes, cerca de 12 minutos no total.

A AUC de teste vai de 0,33 a 0,67. O classificador de maior acurácia e maior AUC é a ResNet50 com três fases no corte central (acurácia de 0,71 e F1 de 0,50), e o de maior F1 é a VGG16 com uma fase e máximo dos cortes (0,59). Como referência, responder "sem pCR" para todos os pacientes do teste dá acurácia de 0,66: só a ResNet50 de três

Tabela 5. Resultados no conjunto de teste com o limiar escolhido na validação. O tempo é o do treino do modelo; média e máximo usam o mesmo modelo.

Rede	Regime	Cortes	Limiar	Sens.	Espec.	Prec.	Acur.	F1	AUC	Tempo (s)
CNN	1 fase	central	0,55	0,33	0,48	0,25	0,43	0,29	0,44	19
CNN	3 fases	central	0,50	0,50	0,52	0,35	0,51	0,41	0,56	18
ResNet50	1 fase	central	0,51	0,67	0,35	0,35	0,46	0,46	0,53	19
ResNet50	3 fases	central	0,54	0,42	0,87	0,62	**0,71**	0,50	**0,67**	28
VGG16	1 fase	central	0,51	0,42	0,65	0,38	0,57	0,40	0,49	35
VGG16	3 fases	central	0,52	0,08	0,78	0,17	0,54	0,11	0,57	44
CNN	1 fase	média	0,51	0,75	0,09	0,30	0,31	0,43	0,52	57
CNN	3 fases	média	0,46	0,83	0,30	0,38	0,49	0,53	0,62	69
ResNet50	1 fase	média	0,66	0,25	0,78	0,38	0,60	0,30	0,61	91
ResNet50	3 fases	média	0,56	0,17	0,91	0,50	0,66	0,25	0,66	90
VGG16	1 fase	média	0,49	0,33	0,78	0,44	0,63	0,38	0,63	114
VGG16	3 fases	média	0,49	0,42	0,65	0,38	0,57	0,40	0,63	137
CNN	1 fase	máximo	0,52	0,25	0,52	0,21	0,43	0,23	0,33	57
CNN	3 fases	máximo	0,52	0,83	0,26	0,37	0,46	0,51	**0,67**	69
ResNet50	1 fase	máximo	0,80	0,17	0,74	0,25	0,54	0,20	0,55	91
ResNet50	3 fases	máximo	0,61	0,42	0,74	0,45	0,63	0,43	0,63	90
VGG16	1 fase	máximo	0,50	0,83	0,48	0,45	0,60	**0,59**	0,61	114
VGG16	3 fases	máximo	0,54	0,25	0,78	0,38	0,60	0,30	0,64	137

fases no corte central supera esse valor. Entre as formas de combinar os cortes, a média teve a maior AUC (0,61 na média dos seis modelos), seguida do máximo (0,57) e do corte central (0,54).

O limiar tem grande efeito sobre as métricas. Com o limiar fixo em 0,5, a acurácia média dos 18 classificadores é 0,48 e metade deles tem especificidade abaixo de 0,35, porque o peso da classe pCR na loss desloca as probabilidades para cima. Com o limiar da validação, a acurácia média sobe para 0,54 e só quatro classificadores ficam abaixo dessa especificidade. O F1 médio cai de 0,48 para 0,37, o que é esperado: o F1 só olha para a classe positiva e é favorecido por classificar muitos pacientes como pCR. Os resultados completos com os dois limiares estão no arquivo `metricas.csv`.

A Figura 3 mostra a convergência dos modelos treinados com todos os cortes. A loss de treino cai de forma regular nas redes pré-treinadas, mas a de validação sobe já nas primeiras épocas e a melhor época é a primeira em três dos seis modelos. A CNN de uma fase é a exceção: sua loss de treino não sai de 1,05. No corte central o comportamento é o da tentativa T5 da Figura 2, com a melhor época entre a terceira e a quarta nas redes pré-treinadas.

5.3. Exemplos de acertos e erros e Grad-CAM

A Figura 4 traz um acerto e um erro da ResNet50 de três fases no corte central. Nos dois casos a probabilidade fica perto do limiar (0,54 e 0,50) e o mapa de calor se concentra fora do tumor. Probabilidades pouco separadas são a regra: no corte central, 80% das saídas de cada rede pré-treinada no teste cabem em uma faixa de no máximo 0,08 em torno de 0,5. A Tabela 6 quantifica a relação entre o mapa e o tumor em todo o conjunto de teste.

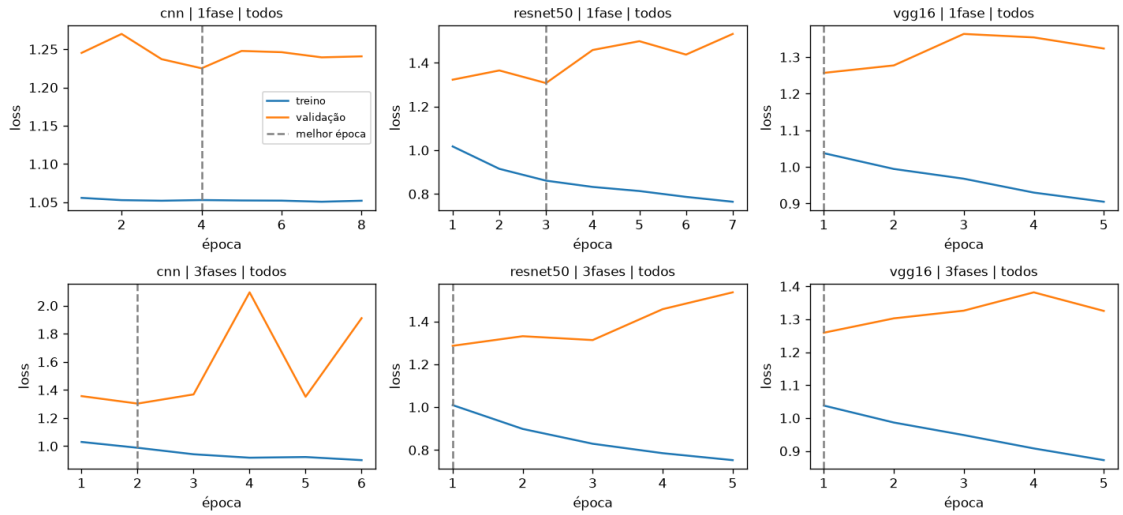


Figura 3. Loss de treino e de validação no treino final com todos os cortes.

Tabela 6. Relação entre o Grad-CAM e o tumor no conjunto de teste, nos regimes de uma e de três fases. "Pico" é a fração das imagens com o ponto mais quente do mapa dentro do tumor e "calor" é a fração do calor do mapa dentro do tumor. A última coluna é o valor esperado de "calor" para um mapa ao acaso.

		Pico no tumor		Calor no tumor		Área do
Rede	Treino	1 fase	3 fases	1 fase	3 fases	tumor
CNN	corte central	0%	0%	0,5%	0,1%	1,6%
ResNet50	corte central	9%	3%	2,8%	2,5%	1,6%
VGG16	corte central	9%	23%	3,3%	4,7%	1,6%
CNN	todos os cortes	47%	15%	7,1%	6,1%	1,2%
ResNet50	todos os cortes	1%	2%	1,2%	2,1%	1,2%
VGG16	todos os cortes	2%	5%	1,1%	2,5%	1,2%

6. Discussão

6.1. Hiperparâmetros, overfitting, underfitting e convergência

Overfitting. Com 104 pacientes de treino, o risco dominante é decorar o treino. Seis medidas o controlam: bases pré-treinadas congeladas, cabeças pequenas (de 2 mil a 33 mil parâmetros), média global no lugar de camadas totalmente conectadas grandes, *dropout*, decaimento de pesos e aumento de dados. O *early stopping* é a medida final: ele guarda a época de menor loss de validação. As curvas mostram que ele atua cedo. No corte central, a loss de treino da ResNet50 cai de 1,05 para 0,94 em 11 épocas enquanto a de validação sobe a partir da terceira. Com todos os cortes, a rede vê 25 vezes mais imagens por época, mas elas vêm dos mesmos 104 pacientes, e a validação piora ainda antes.

Underfitting. Ocorreu em dois casos. Com taxa de aprendizado de 10^{-5}, 40 épocas não bastam para mover a loss de treino. E a CNN própria de uma fase, treinada com todos os cortes e decaimento de 10^{-2}, ficou com loss de treino constante em 1,05 e saídas entre 0,50 e 0,52 para todos os pacientes, o que indica que a regularização que ajudou no corte central foi forte demais nesse caso.

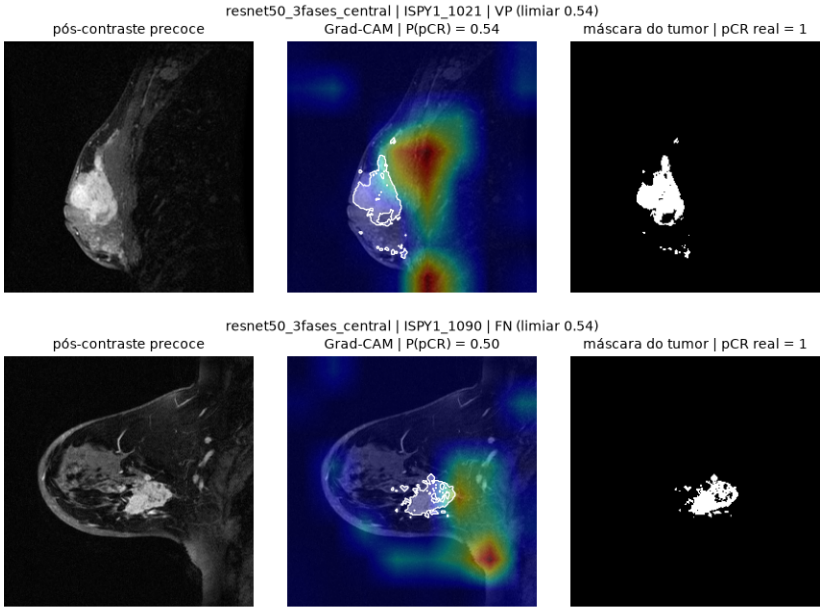


Figura 4. Exemplos da ResNet50 de três fases no corte central: um verdadeiro positivo (acima) e um falso negativo (abaixo). O contorno branco no painel central é a segmentação do tumor.

Velocidade de convergência. A taxa de 10^{-3} leva as redes pré-treinadas à melhor época em 3 ou 4 passagens pelo treino no corte central e em 1 a 3 com todos os cortes. Com a paciência de 8 e de 4 épocas, nenhum treino passou de 26 épocas, o que explica os tempos de segundos a poucos minutos.

Demais hiperparâmetros. O tamanho do lote e o *dropout* não alteraram a validação além do ruído (T6 e T7). O limiar escolhido na validação corrige a tendência a prever pCR criada pelo peso das classes, mas é estimado com 33 pacientes e por isso é instável: variou de 0,46 a 0,80 entre os modelos.

6.2. Respostas às perguntas do trabalho

As três fases produzem resultados melhores que uma fase? No treino final, a AUC de teste com três fases foi maior nos nove pares comparados (mesma rede e mesma combinação de cortes), com média de 0,63 contra 0,52. Essa tendência, porém, não permite confirmar a hipótese. O erro padrão da AUC com 35 pacientes de teste é de cerca de 0,10, igual à diferença observada. Nos 63 pares do ajuste, com três sementes, a diferença média caiu para 0,02 no teste e foi de $-0{,}02$ na validação. Além disso, os nove pares usam os mesmos pacientes de teste e não são independentes. A conclusão é que os dados não mostram prejuízo no uso das três fases e sugerem um ganho pequeno, que só um conjunto maior poderia confirmar.

Qual rede teve melhor desempenho? Na média de seus seis classificadores, a ResNet50 teve acurácia de 0,60 e AUC de 0,61, a VGG16 0,59 e 0,59, e a CNN própria 0,44 e 0,52. As duas redes pré-treinadas ficaram equivalentes e acima da CNN própria, que tem de aprender todos os filtros com poucos dados. O melhor classificador isolado foi a ResNet50 de três fases no corte central, mas o intervalo de confiança de 95% da sua AUC, de aproximadamente 0,47 a 0,87, inclui o acaso.

Quais erros são mais frequentes? Depende do limiar. Com o limiar fixo em 0,5 predominam os falsos positivos: 65% dos pacientes sem pCR são classificados como pCR, contra 27% de falsos negativos entre os pacientes com pCR. Com o limiar da validação os erros se equilibram em número (168 falsos positivos e 121 falsos negativos nos 18 classificadores), mas a taxa de falsos negativos passa a ser a maior: 56% dos pacientes com pCR deixam de ser identificados, contra 41% de falsos positivos.

O Grad-CAM destaca as regiões tumorais? Em geral, não. Nas redes pré-treinadas, o ponto mais quente do mapa cai dentro do tumor em no máximo 23% das imagens e a fração de calor dentro do tumor fica entre 1 e 3 vezes a esperada ao acaso (Tabela 6). A CNN do corte central olha para fora da lesão. A exceção é a CNN treinada com todos os cortes, cujo mapa concentra no tumor de 5 a 6 vezes mais calor que o acaso, sem que isso se traduza em melhor classificação. Parte do resultado se deve à resolução do mapa: na ResNet50 ele tem 8×8 células, cada uma maior do que muitos tumores.

Quais as principais limitações? (i) O conjunto é pequeno: 104 pacientes de treino, 33 de validação e 35 de teste tornam instáveis o ajuste, o limiar e a comparação entre modelos. (ii) O tumor ocupa cerca de 2% da imagem de entrada, e as redes não recebem indicação de onde ele está; usar a máscara como canal ou recortar a imagem na lesão é o próximo passo natural. (iii) As bases congeladas foram treinadas em fotografias e não foram adaptadas à ressonância. (iv) As estratégias avaliadas tratam cada corte isoladamente e não usam a informação tridimensional. (v) O treino final usou uma única semente. (vi) Dados clínicos como o subtipo molecular, sabidamente ligados à pCR, não foram usados por exigência do enunciado.

7. Conclusão

O sistema desenvolvido cumpre as funções propostas: visualização dos volumes com a segmentação, aumento de dados, treino de três redes em dois regimes, três formas de combinar cortes e classificação com Grad-CAM. Os classificadores, porém, ficaram próximos do acaso, e o ajuste de hiperparâmetros mostrou que o limite não está na configuração do treino, mas na quantidade de dados e na forma de apresentar o tumor à rede. O uso das três fases mostrou tendência de ganho no teste, sem significância estatística.

Referências

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K. e Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition*, p. 248–255.

Fridman, N. et al. (2026). BreastDCEDL: A standardized deep learning-ready breast DCE-MRI dataset of 2,070 patients. *Scientific Data*, 13(1):264.

He, K., Zhang, X., Ren, S. e Sun, J. (2016). Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, p. 770–778.

Hylton, N. M. et al. (2012). Locally advanced breast cancer: MR imaging for prediction of response to neoadjuvant chemotherapy – results from ACRIN 6657/I-SPY TRIAL. *Radiology*, 263(3):663–672.

Ioffe, S. e Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning*, p. 448–456.

Kingma, D. P. e Ba, J. (2015). Adam: A method for stochastic optimization. In *International Conference on Learning Representations*.

Paszke, A. et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32*, p. 8024–8035.

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. e Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision*, p. 618–626.

Simonyan, K. e Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations*.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. e Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15:1929–1958.

Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer*, 3(1):32–35.